지능화 캡스톤 프로젝트

프로젝트 #1 결과 발표

2024. 04. 29

충북대학교 산업인공지능학과 [3조] 이선경, 김정식(16)

프로젝트 수행체계

수행방법

- ✓ 1차. 딥러닝 개발환경 구축(~03.18)
- ✓ 2차. 데이터 파악, 구축, CNN 모델 설계 등에 대한 역할 분담(~3.25)
- ✓ 3차. 모델학습, 혼동행렬, 시각화 등을 수행(~04.22)
- ✓ 4차. 코드수정, 발표자료 작성 등을 수행(~04.29)

업무분장

이름	수행내용	비고
이선경	• 데이터 SET 구현, CNN 설계 및 구현, 모델학습 등	
김정식	• 자료조사, PPT 작성	

연구 방법

데이터 증량에 따른 모델 성능 비교(원본/증대 DataSet 비교)

- ✓ 클래스 불균형을 해결하기 위해 데이터 증대기술 적용*
 - * 1.이미지를 텐서로 변환하고 증강 적용, 2. 텐서를 PIL 이미지로 다시 변환, 3. 증강된 이미지 저장
- ✔ 모델의 일반화 능력 향상, 과적합 방지, 클래스 불균형 해소, 성능지표 개선 등

다양한 딥러닝 아키텍처와 CNN-WDI, CNN-CREATE 모델의 비교

- ✓ CNN은 이미지 분류 및 객체 인식과 같은 간단한 작업에 적합하며, 모델 구조가 간단함
- ✓ CNN-WDI, CNN-CREATE는 더 복잡한 이미지 분류나 인식 작업에 사용하는것이 더 편리함
- ✓ Inception 모듈을 사용하여 다양한 크기와 종류의 특징을 추출하는데 용이함



<u>가중치를 사용하여 특정 특징에 더 많은 가중치를 부여할 수 있어서</u> 더 정확한 결과를 얻을 수 있을것으로 예상

데이터셋_데이터증강함수

데이터 증강 함수

```
lef augment_images(image_folder, target_count=10000):
    images = [os.path.join(image_folder, img) for img in os.listdir(image_folder)]
   if current_count < target_count:</pre>
       print(f"Augmenting images in {image_folder}...")
       while current_count < target_count:</pre>
           for img_path in images:
                if current_count >= target_count:
                image = Image.open(img_path)
                augmented_image = transform(image)
                augmented_image = to_pil(augmented_image)
                augmented_image_path = f"{img_path.rsplit('.', 1)[0]}_aug_{current_count}.{img_path.rsplit('.', 1)[-1]}
                augmented_image.save(augmented_image_path)
                current_count += 1
for defect_type in defect_types:
   image_folder = os.path.join(data_dir, 'train', defect_type)
   augment_images(image_folder)
```


데이터셋_데이터증강

데이터 증강 기법

➤ Horizontal Flip, Vertical Flip, Rotation +/-20 degrees


```
def visualize_augmentations(image, transformations, descriptions, save_path=None, dpi=150):
   cols, rows = 3, 3
   fig, axes = plt.subplots(rows, cols, figsize=(cols * 2, rows * 2), dpi=dpi)
   axes = axes.flatten()
   axes[0].imshow(np.asarray(image), interpolation='nearest')
   axes[0].set_title('Original')
   axes[0].axis('off')
   for i, (transformation, description) in enumerate(zip(transformations, descriptions), start=1):
       transformed_image = transformation(image)
       axes[i].imshow(np.asarray(transformed_image), interpolation='nearest')
       axes[i].set_title(description)
       axes[i].axis('off')
   for i in range(3, 9):
       degree = random.uniform(-20, b: 20)
       rotation = transforms.RandomRotation(degrees=(degree, degree))
       transformed_image = rotation(image)
       axes[i].imshow(np.asarray(transformed_image), interpolation='nearest')
       axes[i].set_title(f' {degree:.2f} degrees')
       axes[i].axis('off')
   plt.tight_layout()
   if save_path:
       plt.savefig( *args: save_path, dpi=dpi)
   plt.show()
```





데이터셋_실행결과

데이터 증강




'Train' 세트에 대해서만 데이터 증강 수행

CNN 구조

CNN 구조

- ✓ <u>Model Architecture</u>: 여러 개의 컨벌루션 및 조밀한 레이어를 갖춘 CNN 구조 및 ReLU 활성화 함수를 사용, 다중 클래스 분류를 위한 Softmax 활성화
- ✓ <u>Performance Evaluation</u>: 정확도를 측정하기 위해 테스트 데이터를 기반으로 모델을 평가하였으며 혼돈 행렬, 정밀도, 재현율 및 F1 점수를 평가
- ✓ Visualization: 다양한 컨볼루셔널 레이어의 기능 맵 시각화, 입력 이미지 모델의 반응



*Note: IN denotes input layer; C convolutional layer; P pooling layer; DO dropout layer; FC fully connected layer; OUT output layer; and BN batch normalization

CNN 구조_모델 아키텍처

모델 아키텍처 정의

```
ass Create_CNN(nn.Module):
 def __init__(self):
     super(Create_CNN, self).__init__()
     self.conv1 = nn.Conv2d(in channels=3, out channels=16, kernel size=3, padding=1)
     self.bn1 = nn.BatchNorm2d(num_features=16)
     self.pool1 = nn.MaxPool2d(kernel size=2, stride=2)
     self.conv2 = nn.Conv2d(in channels=16, out channels=16, kernel size=3, padding=1)
     self.bn2 = nn.BatchNorm2d(num features=16)
     # Conv-Pool-Conv 그룹 2
     self.conv3 = nn.Conv2d(in_channels=16, out_channels=32, kernel_size=3, padding=1)
     self.bn3 = nn.BatchNorm2d(num features=32)
     self.pool2 = nn.MaxPool2d(kernel_size=2, stride=2)
     self.conv4 = nn.Conv2d(in_channels=32, out_channels=32, kernel_size=3, padding=1)
     self.bn4 = nn.BatchNorm2d(num_features=32)
     # Conv-Pool-Conv 그룹 3
     self.conv5 = nn.Conv2d(in_channels=32, out_channels=64, kernel_size=3, padding=1)
     self.bn5 = nn.BatchNorm2d(num features=64)
     self.pool3 = nn.MaxPool2d(kernel_size=2, stride=2)
     self.conv6 = nn.Conv2d(in_channels=64, out_channels=64, kernel_size=3, padding=1)
     self.bn6 = nn.BatchNorm2d(num features=64)
     # Conv-Pool-Conv 그룹 4
     self.conv7 = nn.Conv2d(in_channels=64, out_channels=128, kernel_size=3, padding=1)
     self.bn7 = nn.BatchNorm2d(num features=128)
     self.pool4 = nn.MaxPool2d(kernel_size=2, stride=2)
     self.conv8 = nn.Conv2d(in_channels=128, out_channels=128, kernel_size=3, padding=1)
     self.bn8 = nn.BatchNorm2d(num features=128)
     self.dropout = nn.Dropout2d(p=0.2) # Spatial Dropout
     # 완전연결 계층
     self.fc1 = nn.Linear(in_features=128 * 4 * 4, out_features=512)
     self.bn fc1 = nn.BatchNorm1d(num features=512)
     self.fc2 = nn.Linear(in_features=512, out_features=9) # 클래스 수에 맞게 조정
 def forward(self, x):
     x = F.relu(self.bn1(self.conv1(x)))
     x = self.pool1(F.relu(self.bn2(self.conv2(x))))
     x = F.relu(self.bn3(self.conv3(x)))
     x = self.pool2(F.relu(self.bn4(self.conv4(x))))
     x = F.relu(self.bn5(self.conv5(x)))
     x = self.pool3(F.relu(self.bn6(self.conv6(x))))
     x = F.relu(self.bn7(self.conv7(x)))
     x = self.pool4(F.relu(self.bn8(self.conv8(x))))
     x = self.dropout(x) # Spatial Dropout 적용
    x = x.view(-1, 128 * 4 * 4) # Flatten the tensor
x = F.relu(self.bn_fc1(self.fc1(x)))
     x = self.fc2(x)
     return F.log softmax(x, dim=1) # Softmax 활성화 함수
```

CNN 구조

주요 코드 및 실행 결과

- ✓ 딥러닝 프레임워크(PyCharm, pytorch, Python)
- ✓ 오토인코더 모델 생성 및 학습(epoch = 50, batch_size = 1024)

학습 코드

학습 결과

```
for epoch in range(num_epochs): # 전체 데이터셋을 여러 번(50) 반복
   running_loss = 0.0
   correct = 0
   total = 0
   epoch_start = datetime.datetime.now()
   for images, labels in tgdm(train_loader, desc=f'Epoch {epoch+1}', leave=False):
       images, labels = images.to(device), labels.to(device)
      optimizer.zero_grad()
       outputs = model(images)
      loss = criterion(outputs, labels)
       loss.backward()
       optimizer.step()
      running_loss += loss.item()
       _, predicted = torch.max(outputs.data, 1)
       total += labels.size(0)
       correct += (predicted == labels).sum().item()
```

```
Epoch 2/58 | Best 96.78% | Acc/trn 92.26% | Acc/val 96.78% | Time/e 2.74m | Elapsed hrs 8.09h | Exp.end date 282
s|Epoch 3/50 | Best 96.78% | Acc/trn 94.86% | Acc/val 96.71% | Time/e 2.45m | Elapsed hrs 0.13h | Exp.end date 202
s|Epoch 5/50 | Best 96.89% | Acc/trn 96.14% | Acc/val 96.78% | Time/e 2.69m | Elapsed hrs 0.22h | Exp.end dat
| Epoch | 6/50 | Best 97.30% | Acc/trn 96.49% | Acc/val 97.30% | Time/e 2.46m | Elapsed hrs 0.26h | Exp.end date
 | Epoch 21/50 | Best 97.80% | Acc/trn 99.99% | Acc/val 97.66% | Time/e 2.50m | Elapsed hrs 0.88h | Exp.end date 202
  Epoch 23/50 | Best 97.80% | Acc/trn 99.99% | Acc/val 97.61% | Time/e 2.49m | Elapsed hrs 0.96h | Exp.end date
```

CNN 시각화_정확도 및 손실

정확도 및 손실 상세코드

```
model = Create_CNN().to(device)
criterion = nn.CrossEntropyLoss()
optimizer = optim.Adam(model.parameters(), lr=0.01)
scheduler = optim.lr_scheduler.StepLR(optimizer, step_size=10, qamma=0.1) # 학습률 스케줄러 설정
Jdef validate(model, val_loader, criterion):
    model.eval()
    val_loss = 0.0
    correct = 0
                                                                                                    정확도 및 손실도 시각화
    with torch.no_grad():
        for images, labels in val_loade
                                                         Training and Validation Loss
                                                                                                            Training and Validation Accuracy
            images, labels = images.to(
            outputs = model(images)
                                                                                                 100
            loss = criterion(outputs,
                                           0.25
            val_loss += loss.item() * :
                                                                                                  98
            _, predicted = torch.max(ou
                                           0.20
            total += labels.size(0)
            correct += (predicted == la
                                                                                               Accuracy
                                                                                                  96
                                         SSO 0.15
    val_loss /= total # 평균 손실 계산
                                                                               Train Loss
                                                                            --- Validation Loss
    val_accuracy = 100 * correct / tota
    return val_loss, val_accuracy
                                           0.10
                                                                                                  94
                                           0.05
                                                                                                  92
                                                                                                                                 Train Accuracy

    Validation Accuracy


                                            0.00
                                                         10
                                                                 20
                                                                         30
                                                                                                              10
                                                                                  40
                                                                                          50
                                                                                                                      20
                                                                                                                              30
                                                                                                                                      40
                                                                                                                                              50
                                                                   Epochs
                                                                                                                        Epochs
```

CNN 시각화_혼돈행렬

혼돈행렬 상세코드

```
def compute_confusion_matrix(model, data_loader, device):
   nb classes = 9
   confusion_matrix = np.zeros((nb_classes, nb_classes))
    with torch.no_grad():
        for i, (inputs, classes) in enumerate(data_loader):
            inputs = inputs.to(device)
            classes = classes.to(device)
            outputs = model(inputs)
            _, preds = torch.max(outputs, 1)
           for t, p in zip(classes.view(-1), preds.view(-1)):
                confusion_matrix[t.long(), p.long()] += 1
    return confusion matrix
train_confusion_mtx = compute_confusion_matrix(model, train_loader, device)
test_confusion_mtx = compute_confusion_matrix(model, test_loader, device)
class_names = train_data.classes
def visualize_performance(train_cm, test_cm, classes):
    fig. (ax1, ax2) = plt.subplots(1, 2, figsize=(20, 10))
    plot_confusion_matrix(train_cm, classes=classes, ax=ax1, normalize=True, title=
    plot_confusion_matrix(test_cm, classes=classes, ax=ax2, normalize=True, title=
    plt.show()
```


혼돈행렬 시각화



CNN 시각화_Balanced data 비교

Confusion matrix 비교(actual label 기준 비율)





Train Dataset

Test Dataset

학습 방법

딥러닝 학습 조건

- (HW) PC 사양, 학습시간

CPU: Intel Xeon CPU E5-2696 v5 @ 4.40GHz

RAM: 512GB

GPU: NVIDIA GeForce GTX 1080 24GB

GPU 사용량

```
C:\Users\user>nvidia-smi
Fri Apr 12 20:09:10 2024
 NVIDIA-SMI 531.79
                                   Driver Version: 531.79
                                                                CUDA Version: 12.1
                                TCC/WDDM | Bus-Id
                                                                  Volatile Uncorr. ECC
  GPU
      Name
                                                         Disp.A
                                                                  GPU-Util Compute M.
 Fan Temp Perf
                            Pwr:Usage/Cap
                                                   Memory-Usage
                                                                                MIG M.
   0 NVIDIA GeForce GTX 1650 T... WDDM |
                                           00000000:02:00.0 Off
                                                                                   N/A
 N/A
       64C
                               33W / N/A
                                             1360MiB / 4096MiB
                                                                               Default
              P0
                                                                      48%
                                                                                   N/A
  Processes:
  GPU
        GI
             CI
                       PID
                             Type
                                                                            GPU Memory
                                    Process name
        ID
             ID
                                                                            Usage
```

모델의 성능

딥러닝 학습 결과

- 불균형 데이터셋과 균형잡힌 데이터셋에 대한 모델의 성능 비교

	Precision	Recall	F1-score	
Center	99.2	98.6	98.9	
Donut	99.8	99.9	99.8	
Edge-Loc	98.3	96.2	97.2	
Edge-Ring	99.3	99.7	99.5	
Loc	97.5	96.6	97.1	
Near-full	100.0	100.0	100.0	
Random	99.8	100.0	99.9	
Scratch	98.7	98.7	98.7	
none	99.5	99.8	99.6	
Average	99.1	98.8	99.0	

	Precision	Recall	F1-score	
Center	93.3	96.0	94.6	
Donut	82.6	83.5	83.1	
Edge-Loc	86.0	80.1	82.9	
Edge-Ring	97.9	98.3	98.1	
Loc	83.1	74.9	78.8	
Near-full	95.7	91.7	93.6	
Random	87.3	92.3	89.7	
Scratch	75.1	69.7	72.3	
none	98.9	99.3	99.1	
Average	88.9	87.3	88.0	


Train Dataset

Test Dataset

결과 및 토의

모델별 분류 성능 비교

- CNN-CREATE 모델이 전반적으로 높은 성능을 보임.





CNN-WDI

CNN-CREATE

Classfier	Training Acc	Validation Acc	Testing Acc	Precision	Recall	F1-Score
CNN-CREATE	98.8	97.8	97.8	97.5	97.5	97.5
CNN-WDI	98.9	96.4	96.2	96.2	96.2	96.2
CNN-D	97.6	95.5	95.2	95.2	95.2	95.2
CNN-BN	99.4	95.6	95.6	95.6	95.6	95.6
CNN-SD	98.6	94.7	94.8	94.8	94.8	94.8
VGG-16	82.3	80	80.1	80.3	80.1	79.9
ANN	95.9	95.9	72	95.2	95.9	95.4
SVM	91.3	91	32.6	87.5	91	88

결론

결과 요약 및 의미

- CNN-CREATE 모델은 일관되게 높은 정확도, 성능 지표 나타냄. 해당 문제에 대한 특화된 접근 방식과 최적화를 통해 강력한 일반화 능력을 갖춤
- 맞춤형 아키텍처, 고급 성능 지표의 향상, 효율적인 학습 전략을 결합하여 높은 수준의 성과를 달성

개선점

- 계산 효율성 측면에서 개선하고자 모델의 계산 복잡성을 낮추고 추론 속도를 향상시키는 방안 탐색
- 모델의 Robustness를 추가적으로 평가하고, 특정 클래스에 대한 분류 성능을 개선하기 위한 추가적인 데이터 증강 기법 고려

감사합니다